

Evroliga

Predviđanje ishoda utakmice

Binarni klasifikacioni model za predviđanje pobjednika košarkaške utakmice na osnovu istorijskih podataka i forme timova.

David Boljanić · RA 45/2023

1. Kratak opis projekta

Cilj projekta je izgradnja funkcionalnog modela mašinskog učenja koji predviđa ishod košarkaške utakmice u Evroligi — ko će pobediti, domaći tim ili gostujući tim. Pošto u košarci nerešen rezultat nije moguć, radi se o binarnoj klasifikaciji: pobjeda domaćina (1) ili pobjeda gosta (0).

Predviđanje se vrši isključivo na osnovu informacija dostupnih **pre** odigravanja utakmice — identitet timova, faza takmičenja, sezona i statistike iz prethodnih utakmica.

■ Inicijalna ideja i problem sa podacima

Prvobitna ideja projekta bila je predviđanje **učesnika Final Four faze** Evrolige — dakle, koji će timovi na kraju sezone ući u završnicu turnira. Međutim, pri analizi dostupnih podataka naišao sam na ozbiljan problem: Evroliga postoji od sezone 2007/2008, što znači da postoji svega **19 Final Four turnira** do danas. Sa samo 19 primera, nijedan model mašinskog učenja nije u stanju da nauči smislene obrasce — to je statistički prenizak broj instanci za bilo kakvu pouzdanu predikciju.

Zbog toga sam promenio pristup i fokusirao se na predviđanje ishoda **pojedinačnih utakmica**, gde je dostupno ~5.000 primera kroz sve sezone, što je znatno pogodnije za treniranje modela.

2. Analiza podataka

Podaci potiču iz javno dostupnog skupa **Euroleague & Eurocup Datasets** (Kaggle), koji pokriva sve utakmice Evrolige od sezone 2007/2008 do sezone 2024/2025. Korišćena je osnovna tabela utakmica (Header CSV) — `euroleague_header.csv` — koja sadrži po jedan red za svaku odigranu utakmicu. Napomena: skup podataka na Kaggleu sadrži i Eurocup podatke u zasebnom fajlu, ali oni nisu korišćeni. To se može potvrditi činjenicom da svi season codevi u korišćenom fajlu počinju prefiksom `E` (npr. `E2007`, `E2024`), što je isključivo Euroleague oznaka — Eurocup bi imao prefiks `U`.

■ Veličina skupa podataka

Skup sadrži ukupno **5.039 utakmica** iz **19 sezona** (2007–2025), sa sledećom distribucijom po fazama takmičenja:

Faza	Broj utakmica	%
Regular Season	3.981	79%
TOP 16	673	13%
Playoffs	290	6%
Final Four	71	1%
Play-In	9	<1%

Napomena: TOP 16 je bio drugi grupni deo starog formata Evrolige (2009–2016). Od sezone 2016/17 Evroliga je prešla na sadašnji format bez TOP 16 faze.

■ Distribucija ishoda

Domaći tim pobeđuje u **~60% utakmica**, gostujući tim u **~40%**, što odražava poznati fenomen prednosti domaćeg terena. Ova neravnoteža klasa uzeta je u obzir pri treniranju kroz podešavanje `class_weight` parametra i odabirom `balanced_accuracy` kao metrike optimizacije.

■ Korelaciona analiza

Izrađena je korelaciona matrica između svih ulaznih atributa i ciljne promenljive (`result`). Rezultati pokazuju da nijedan atribut sam po sebi nije u visokoj korelaciji sa ishodom, što potvrđuje kompleksnost problema — košarkaški rezultat zavisi od kombinacije više faktora, ne od jednog dominantnog. Ovo je za razliku od, na primer, problema predikcije cene leta gde klasa leta dominantno određuje cenu.

■ Distribucija poena

Analiza distribucije poena domaćina i gosta pokazuje da domaćin u proseku postiže nešto više poena od gosta. Distribucija razlike poena (`homescore - awayscore`) grupirana je oko nule sa blagom asimetrijom u korist domaćina.

3. Priprema podataka

Priprema podataka implementirana je u skripti `src/data_preparation.py`.

■ 3.1 Normalizacija naziva kolona

Kaggle dataset koristi nestandardne nazive kolona koji se razlikuju između verzija (npr. `localclub` umesto `hometeam`, `roadScore` umesto `awayscore`). Implementirana je automatska normalizacija koja mapira sve poznate varijante na standardne nazive, što čini pipeline otpornim na promene u formatu ulaznih podataka.

■ 3.2 Nedostajuće vrednosti

Proverom skupa utvrđeno je da nedostajuće vrednosti postoje uglavnom u kolonama poput `arena` i `city`, koje ionako nisu ulazni atributi modela. Za kolone koje ulaze u model, nedostajuće numeričke vrednosti popunjene su **medijanom**, a kategorijske **najčešćom vrednošću** (mode). Ovim pristupom nije odbačen nijedan red iz skupa podataka.

■ 3.3 Problem duplikata — nazivi timova

Jedan od najvećih problema u pripremi podataka bio je to što **isti košarkaški klub kroz sezone nastupa pod različitim sponzorskim imenima**. Na primer, klub iz Vitorije nastupao je pod sledećim nazivima tokom istorije:

- TAU CERAMICA (2007–2010)
- CAJA LABORAL (2010–2013)
- LABORAL KUTXA VITORIA (2013–2015)
- KIROLBET BASKONIA (2018–2020)
- CAZOO BASKONIA (2021–2022)
- TD SYSTEMS BASKONIA (2022)
- BASKONIA VITORIA-GASTEIZ (2022–danas)

Bez rešavanja ovog problema, model bi iste klubove tretirao kao **16 potpuno različitih entiteta**, što bi značajno narušilo računanje forme i head-to-head statistike. Pored toga, padajući meni aplikacije bi imao 159 stavki umesto 68.

Rešenje: implementiran je dvostepeni algoritam kanonizacije naziva timova u `src/predict.py`:

Korak 1 — Ručna mapa: za klubove sa poznatim sponzorskim promenama unapred su definisani parovi (varijanta → kanonički naziv). Ovim je pokriveno ~30 klubova sa 80+ poznatih varijanti.

Korak 2 — Algoritamsko klasterovanje: za preostale timove, algoritam grupiše nazive na osnovu podudaranja ključnih reči, isključujući generičke pojmove (BC, KK, Basket) i nazive gradova (Istanbul, Madrid, Milano...). Dva naziva se smatraju istim klubom ako se 50% ili više ključnih reči podudara.



Specifičan slučaj: primećeno je da je jedan naziv tima (`CRVENA ZVEZDA MERIDIAN BELGRADE`) bio prisutan samo kao domaćin — nikada kao gost — što je uzrokovalo da `awayteam` label encoder ne poznaje taj naziv. Rešeno je tako što `_safe_encode` funkcija pri enkodiranju proba sve poznate varijante kluba pre nego što padne na rezervnu vrednost.

■ 3.4 Faze takmičenja

Evroliga je menjala format takmičenja, što je rezultovalo različitim nazivima za iste faze (PLAY OFF → PLAYOFFS, TOP SIXTEEN → TOP 16). Pored toga, faza PLAY-IN postoji u bazi sa svega **9 utakmica** — nedovoljno za model da nauči nešto smisleno. Sve PLAY-IN utakmice spojene su u kategoriju PLAYOFFS tokom preprocesiranja.

■ 3.5 Enkodiranje kategorijskih atributa

Atributi `hometeam`, `awayteam` i `phase` konvertovani su u numerički format metodom **Label Encoding** — svakom timu i fazi takmičenja dodeljuje se jedinstven celi broj. Fitovani enkoderi sačuvani su u `models/label_encoders.pkl` kako bi se mogli koristiti pri predikciji bez ponovnog fitovanja.

■ 3.6 Kreiranje novih atributa (Feature Engineering)

Sirovi dataset ne sadrži attribute koji opisuju trenutnu formu timova. Kreirani su:

home_form i away_form

Kumulativni prosek poena tima u svim prethodnim utakmicama tekuće sezone. Forma se **resetuje na početku svake sezone** jer roster, trener i sistem igranja se menjaju iz sezone u sezonu — forma Reala iz 2017. nije relevantna za predikciju utakmice u 2025. Primenjen je `shift(1)` kako rezultat tekuće utakmice ne bi uticao na sopstvenu formu (data leakage).

head_to_head_advantage

Ukupan broj pobeda domaćeg tima nad gostujućim timom u svim prethodnim međusobnim susretima, uzimajući u obzir **sve istorijske nazive** oba kluba.

year

Numerička godina sezone, izdvojena iz atributa `season`.

■ 3.7 Uklanjanje nebitnih atributa

Atributi `date`, `arena` i `city` uklonjeni su iz skupa ulaznih atributa. Datum nije korišćen direktno kao feature jer bi unošenje rednog broja datuma moglo stvoriti veštačke korelacije vezane za specifičan vremenski period — umesto toga, iz datuma je izvučena samo sezona (`year`) koja nosi relevantnu informaciju o vremenskom kontekstu.

4. Odabir i treniranje modela

Treniranje je implementirano u skripti `src/train.py`.

■ 4.1 Podela podataka

Klasična nasumična podela (random split) bila bi pogrešna za ovaj problem jer bi dozvolila modelu da tokom treninga „vidi“ utakmice iz budućih sezona. U realnosti uvek predviđamo budućnost na osnovu prošlosti, pa je primenjena **hronološka podela**:

- **Trening skup:** sezone 2007–2023 (4.031 utakmica — 80%)
- **Test skup:** sezone 2023–2025 (1.008 utakmica — 20%)

Test skup model nikada nije video tokom treniranja.

■ 4.2 Isprobani algoritmi

Isprobana su četiri algoritma klasifikacije:

Logistic Regression — linearni model korišćen kao baseline za poređenje. Zbog linearne prirode zahteva standardizaciju ulaznih atributa (StandardScaler). Jednostavan za interpretaciju, ali ograničen u hvatanju nelinearnih veza između atributa.

Decision Tree — interpretabilan model koji gradi pravila odlučivanja u obliku stabla. Bez ograničenja dubine sklon je preprilagođavanju (overfitting), pa je podešavanje `max_depth` i `min_samples_split` parametara bilo ključno.

Random Forest — ansambl koji paralelno gradi više stabala odlučivanja i uzima prosek njihovih predikcija. Smanjuje varijansu u odnosu na pojedinačno stablo i otporniji je na preprilagođavanje.

XGBoost — boosting algoritam koji iterativno gradi stabla gde svako naredno stablo ispravlja greške prethodnog. Generalno daje dobre rezultate na tabelarnim podacima i bio je konačni odabrani model.

■ 4.3 Podešavanje hiperparametara

Za svaki model primenjen je **GridSearchCV** koji automatski pretražuje sve kombinacije unapred definisanih hiperparametara:

Model	Pretraživani hiperparametri
Logistic Regression	$C \in \{0.01, 0.1, 1, 10\}$, solver $\in \{\text{lbfgs}, \text{liblinear}\}$
Decision Tree	max_depth, min_samples_split, min_samples_leaf
Random Forest	n_estimators, max_depth, min_samples_split, min_samples_leaf
XGBoost	n_estimators, max_depth, learning_rate, subsample

Umesto standardnog k-fold cross-validacije, korišćen je **TimeSeriesSplit** sa 5 foldova. Standardni k-fold nasumično meša podatke i dozvolio bi validaciju na starijim utakmicama pri treniranju na novijim — TimeSeriesSplit to sprečava jer uvek trenira na starijim i validira na novijim podacima u svakom foldu:

```
Fold 1: [====train====][test]
Fold 2: [=====train=====][test]
Fold 3: [=====train=====][test]
Fold 4: [=====train=====][test]
Fold 5: [=====train=====][test]
```

Metrika optimizacije je `balanced_accuracy` koja jednako vrednuje obe klase.

5. Analiza rezultata

Evaluacija je implementirana u skripti `src/evaluate.py`.

5.1 Metrike modela

Model	Accuracy	Precision	Recall	F1
Logistic Regression	58.9%	66.6%	70.3%	68.4%
Decision Tree	60.2%	66.4%	75.0%	70.4%
XGBoost	63.0%	66.8%	82.4%	73.8%
Random Forest	63.4%	66.4%	85.2%	74.6%

5.2 Odabir finalnog modela

Finalni model bira se na osnovu **F1 macro** skora, koji jednako vrednuje obe klase. Obični F1 skor je ponderisan brojem primera po klasi i favorizuje dominantnu klasu — u ovom slučaju domaću pobjedu (~60% primera). F1 macro to izbegava:

Model	F1 macro
Logistic Regression	0.549
Decision Tree	0.548
XGBoost	0.554
Random Forest	0.544

Iako Random Forest ima viši accuracy (63.4%) i obični F1 (74.6%), ima nizak F1 macro (0.544) jer sklono predviđa domaću pobjedu (recall 85%) i slabo prepoznaje gostujuće pobjede. **XGBoost** je uravnoteženiji između oba ishoda i odabran je kao finalni model.

5.3 Zaključci o kvalitetu modela

Tačnost od 63% je solidan rezultat za predviđanje košarkaških utakmica. Profesionalni sportski analitičari i kladionice tipično pogađaju 60–65% utakmica u sportovima sa visokim stepenom neizvesnosti kao što je košarka.

Ograničenja modela potiču iz nedostatka atributa koji opisuju:

- Individualnu kvalitetu igrača i povrede
- Umor i gustinu rasporeda utakmica
- Promene trenera i taktičke prilagodbe
- Motivacione faktore (borba za plasman, eliminacija iz takmičenja)

6. Odabir najznačajnijih atributa

■ 6.1 Feature importance

Za modele zasnovane na stablima (Random Forest, XGBoost, Decision Tree) feature importance se računa na osnovu smanjenja nečistoće (impurity) pri grananjima stabla. Za Logistic Regression koriste se apsolutne vrednosti koeficijenata.

Svi modeli konzistentno identifikuju iste attribute kao najznačajnije:

- 1 **Away Team** — identitet gostujućeg tima
- 2 **Away Form** — kumulativna forma gosta u tekućoj sezoni
- 3 **Home Form** — kumulativna forma domaćina u tekućoj sezoni

■ 6.2 Poređenje: svi vs. top atributi

Random Forest je retreniran koristeći samo top 3 atributa (Away Team, Away Form, Home Form) sa istim hiperparametrima i upoređen sa modelom koji koristi svih 7:

	Broj atributa	Accuracy
Svi atributi	7	63.4%
Top 3 atributa	3	61.2%

Pad od svega 2.2% uz korišćenje samo 3 od 7 atributa ukazuje da identitet gostujućeg tima i forme oba tima nose većinu informacionog sadržaja. Atributi kao što su Home Team, Phase, Year i H2H Advantage dodaju relativno malo prediktivne moći.

7. Zaključak i smernice za unapređenje

Projekat je uspešno realizovao binarni klasifikacioni model koji predviđa ishode Euroleague utakmica sa tačnošću od 63%, što je u skladu sa performansama profesionalnih analitičara u ovoj oblasti. Odabrani model (XGBoost) bolji je kandidat od Random Foresta jer je uravnoteženiji u prepoznavanju oba moguća ishoda.

Potencijalna unapređenja koja bi mogla povećati tačnost modela:

- **Dodatni atributi** — uvođenje prosečnog PIR (Performance Index Rating) igrača u poslednjih N utakmica, broja dana odmora između utakmica, ili podatka o tome da li tim igra treću utakmicu za sedam dana.
- **One-Hot Encoding umesto Label Encodinga** — Label Encoding uvodi implicitno ordinalno uređenje između timova (tim sa kodom 5 nije „bliži“ timu 6 nego timu 1). One-Hot Encoding bi eliminisao ovaj artefakt, uz cenu povećanja dimenzionalnosti.
- **Retraining modela svake sezone** — model je treniran na podacima do 2023. sezone. Godišnje ažuriranje sa novim sezonama bi postepeno poboljšavalo performanse.
- **Proširenje atributa na nivo igrača** — integracija Boxscore tabele iz istog Kaggle skupa omogućila bi uvođenje statistika pojedinih igrača, što bi dalo mnogo bogatiji ulazni prostor za model.